3D Gaussian Splatting for Real-Time Radiance Field Rendering

박누리 2025126659
동국대학교 컴퓨터 AI 학과

연구 배경

- 기존 3D Scene 표현 방식
  - 전통적 그래픽스 방식 (Meshes & Points)
    - Explicit 데이터 형태로 GPU 연산 및 래스터화에 적합하여 렌더링 속도가 빠름
  - 최근 AI 기반 렌더링 (ex. NeRF)
    - 연속적인 공간 표현으로 최고 수준(SOTA)의 화질
    - 렌더링 시 무수히 많은 광선을 쏘아 확률적 샘플링을 해야하므로 연산 비용이 높고 노이즈 발생
- 기존 기술의 한계점
  - 화질이 좋으면 학습과 렌더링이 느리고, 속도를 높이면 화질이 떨어짐
  - 고해상도 고품질의 실시간 렌더링은 어려움

연구 목표

- 그래픽스 방식(빠른 속도)과 NeRF 방식(고품질 연속 표현)의 장점을 결합하여, SOTA급 화질 + 빠른 학습 속도 + 고해상도 실시간 렌더링을 동시에 달성하는 새로운 접근법 제안

3D Gaussian Splatting

- 3D 가우시안 표현
  - 무거운 3D 뼈대(MVS) 없이 수학적으로 미분 가능한 가우시안을 씬의 기본 단위로 사용하여 유연한 학습과 초고속 렌더링의 기반
- 적응형 밀도 제어 및 속성 최적화
  - 가우시안의 형태와 색상을 학습하며, 오차에 따라 점을 복제하거나 분할 및 삭제하여 씬의 디테일을 완벽히 재구성
- 초고속 타일 기반 미분 가능 래스터화
  - 화면을 타일 단위로 나누고 GPU로 초고속 정렬하여, 가시성을 유지하면서도 메모리 폭발 없는 무제한 학습과 고해상도 실시간 렌더링을 달성

Traditional Scene Reconstruction and Rendering

- Traditional Reconstruction
  - 사진들에서 카메라 위치와 희소한 점을 찾는 SfM 기반 위에, 빽빽한 3D 형태를 채우는 MVS 뼈대를 사용해 렌더링
  - 한계 : MVS가 3D 구조를 완벽히 파악하지 못하면 렌더링 화면에 구멍이 뚫리거나, 허공에 존재하지 않는 이상한 덩어리가 생기는 오류 발생

Neural Rendering and Radiance Field

- NeRF
  - 빈 공간을 포함한 3D 공간 전체를 연속적인 볼륨으로 보고, 빛을 쏘아 적분하는 Ray-marching 기법 도입
  - 한계 : 픽셀 하나를 그리기 위해 무수히 많은 지점을 MLP로 계산해야 하므로 렌더링 속도가 느림

Neural Rendering and Radiance Field

- InstantNGP, Plenoxels (속도를 높인 최신 NeRF들)
  - 느린 신경망 대산 공간을 격자로 쪼개에 특성을 저장하는 방식으로 속도 개선
  - 한계 : 여전히 Ray-marching을 사용해야하므로 텅 빈 허공에도 불필요한 계산이 발생하며, 정해진 격자 구조의 한계 때문에 화질 제약 존재

Point-Based Rendering and Radiance Fields

- Point-based Rendering & Splatting
  - 메쉬나 격자 없이 Point만으로 빠르게 화면을 그림. 점 사이의 구멍이나 계단 현상을 막기 위해 점을 타원형으로 넓게 펴 바르는 Splatting 기법 활용
  - 한계 : 최근 AI를 접목한 시도들이 있었으나, 여전히 MVS 뼈대를 사용해야함

NeRF & Point

- NeRF의 연속적인 레이마칭 수식과, 고전적인 포인트 알파 블렌딩 수식은 본질적으로 동일한 이미지 형성 모델임
- NeRF vs Point
  - NeRF는 빈 공간까지 계산해야 하는 무거운 ‘연속적’ 구조이고, Point는 딱 물체가 있는 곳만 계산하면 되는 유연한 ‘비구조화(unstructured) ' 구조라 속도에서 압도적으로 유리함

3D Gaussian Splatting

- 무겁고 오류 많은 MVS 뼈대를 버리고, SfM에서 덤으로 얻는 점 데이터만 사용
- 과거 속도에만 치중해 물체가 겹치는 순서를 무시했던 방식(Pulsar 등)과 달리, Visibility을 존중하는 초고속 정렬 타일 래스터라이저 개발
- 과거 사람 얼굴 등 단일 객체에만 쓰이던 3D 가우시안을 거대하고 복잡한 일상 공간 스케일로 성공적 확장

3D Gaussian Splatting 파이프라인

- Input : 다각도에서 촬영된 Static scene 이미지 세트.
- SfM 초기화 : 카메라 위치/각도 보정 시 부수적으로 얻어지는 Sparse point cloud를 활용

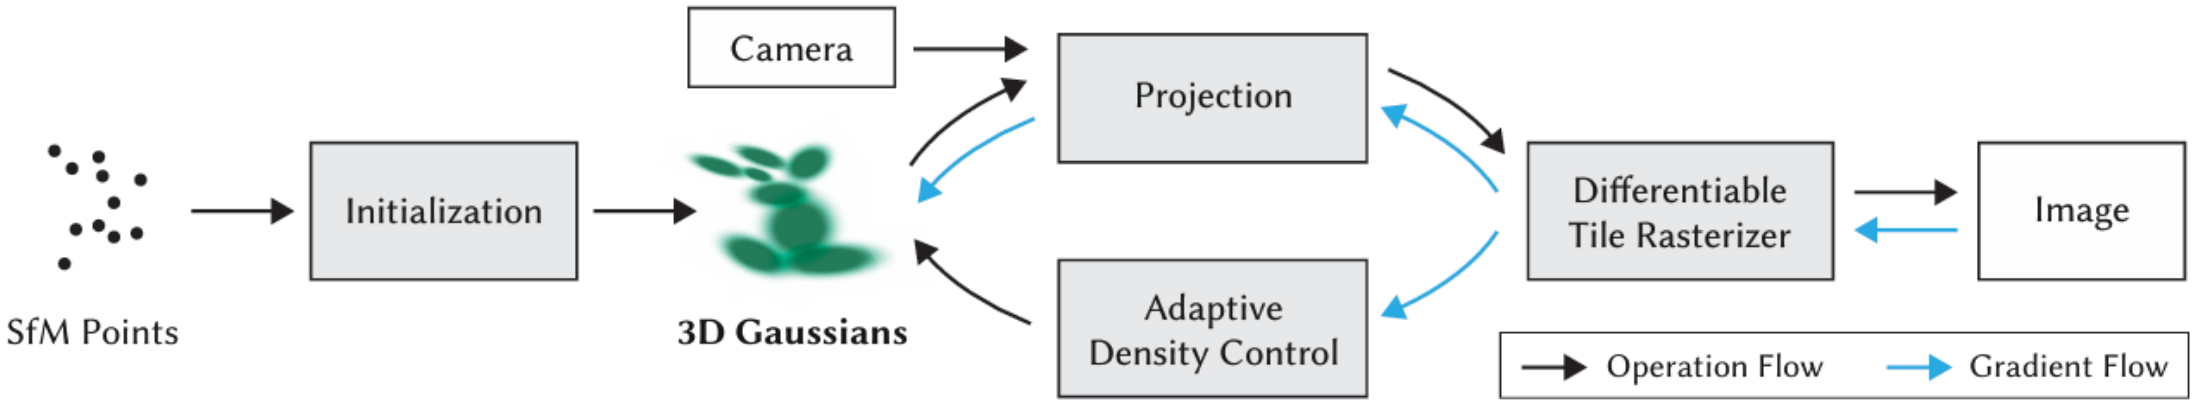

3D Gaussian Splatting 파이프라인

- 3D 가우시안 생성 : SfM 점들을 바탕으로 3D 가우시안 세트 초기화
- 핵심 속성 : 위치, 공분산(Covariance), 불투명도(α)로 정의
- Anisotropic 구조 : 자유롭게 찌그러지는 형태를 통해 복잡한 미세 구조를 압축적으로 표현.
- 색상 : Spherical Harmonics(SH)를 사용해 시점에 따른 빛 반사 및 색상 구현.

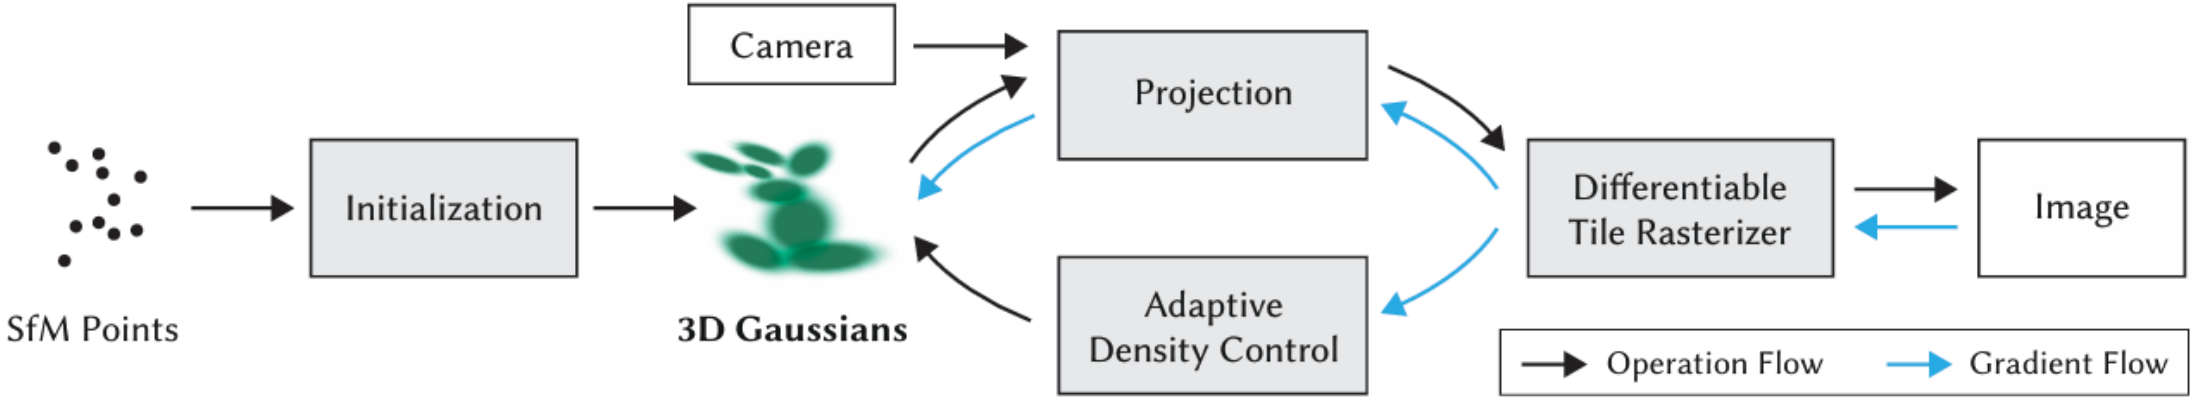

3D Gaussian Splatting 파이프라인

- 파라미터 최적화 : 3D 가우시안의 4대 속성(위치, 공분산, α , SH 계수)을 연속적으로 최적화
- 적응형 밀도 제어 (Adaptive Density Control) : 파라미터 최적화와 교차로 수행.
- 오차에 따라 가우시안의 밀도를 조절하여 씬을 정밀하게 재구성.

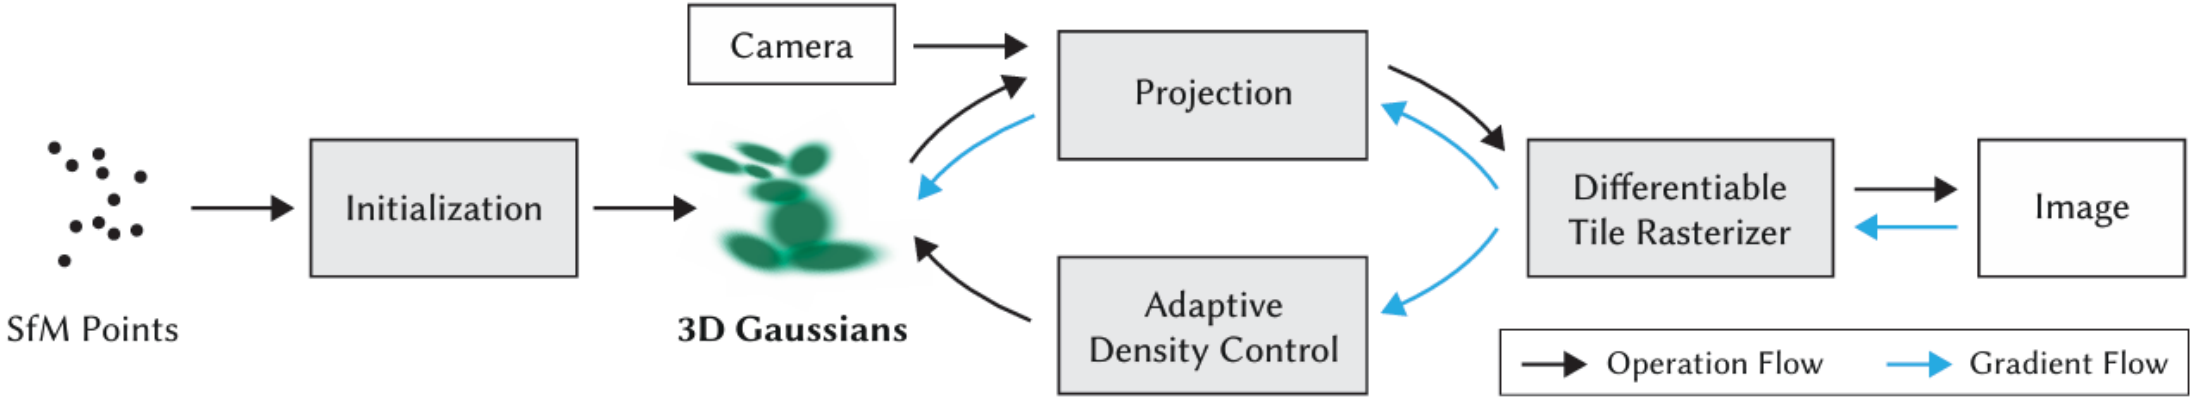

3D Gaussian Splatting 파이프라인

- 실시간 렌더링: 화면을 타일(Tile)로 분할 후, 초고속 정렬을 통해 가우시안을 카메라와 가까운 순서로 정렬
- 가시성(Visibility) 존중: 정렬된 순서로 α -blending을 수행하여, 앞뒤 물체가 겹치는 순서를 정확히 존중.
- Unlimited Backward Pass: 누적된 α 값을 추적하여 오차 피드백을 받는 가우시안 개수에 제한을 두지 않음.

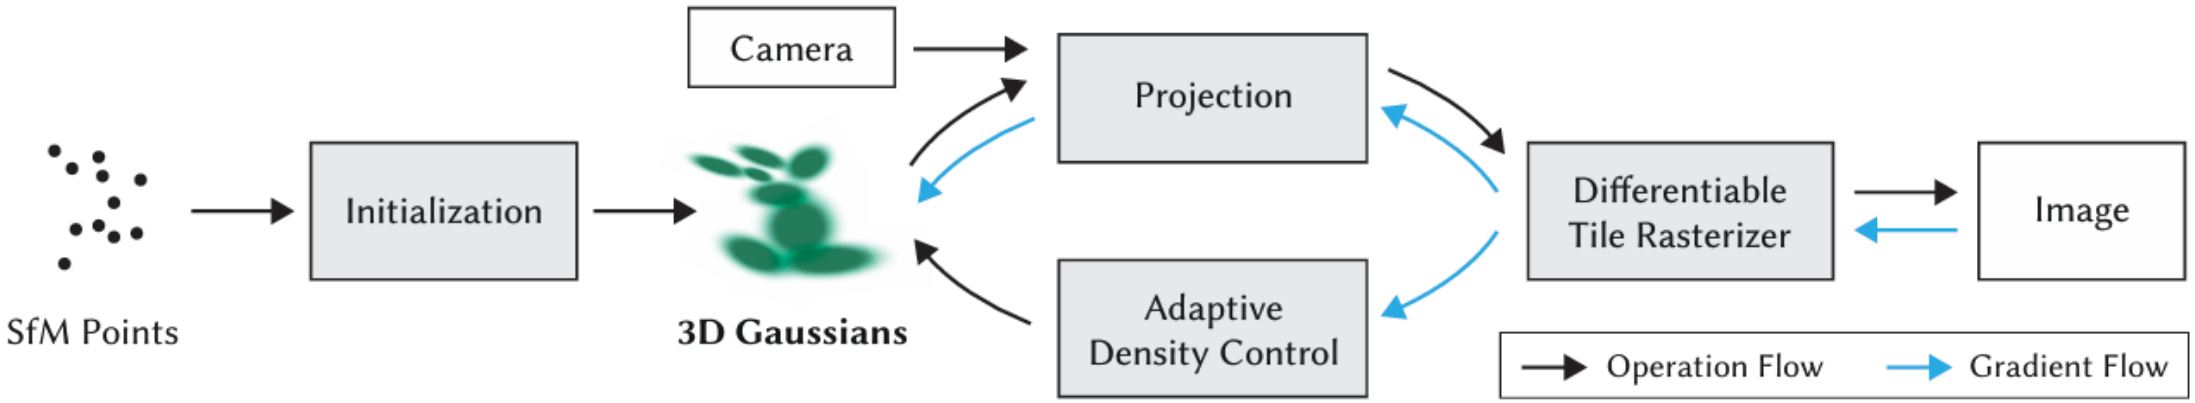

Differentiable 3D Gaussian Splatting

- 기존 포인트 렌더링의 한계 : 점마다 Normal 벡터 필수 -> SfM 데이터는 너무 희소해 정확한 추정 불가 및 노이즈 발생.
- 해결책 : 법선 정보가 전혀 필요 없는 3D 덩어리, 3D Gaussian 을 씬 구성의 기본 블록으로 채택.

3D Gaussian

- Differentiable : AI가 역전파를 통해 오차를 스스로 학습 가능.
- Unstructured : 격자(Grid)에 얽매이지 않고 필요한 공간에만 유연하게 배치되어 연산 극도로 효율적.
- 초고속 2D 투영 : 3D 공간의 가우시안 덩어리를 2D 화면으로 매우 빠르게 납작하게 투영하여 즉각적인 α-blending 지원.

3D Gaussian

- Covariance matrix(∑)
  - 3D 가우시안의 크기와 찌그러진 모양은 ∑ 이라는 수식으로 정의
  - 이를 AI가 경사하강법으로 무작위 학습하면, 수학적 규칙(양의 준정부호)이 깨지면서 부피가 음수가 되는 등 형태가 붕괴되어 에러가 발생하기 쉬움

$$\Sigma' = JW\Sigma W^T J^T$$

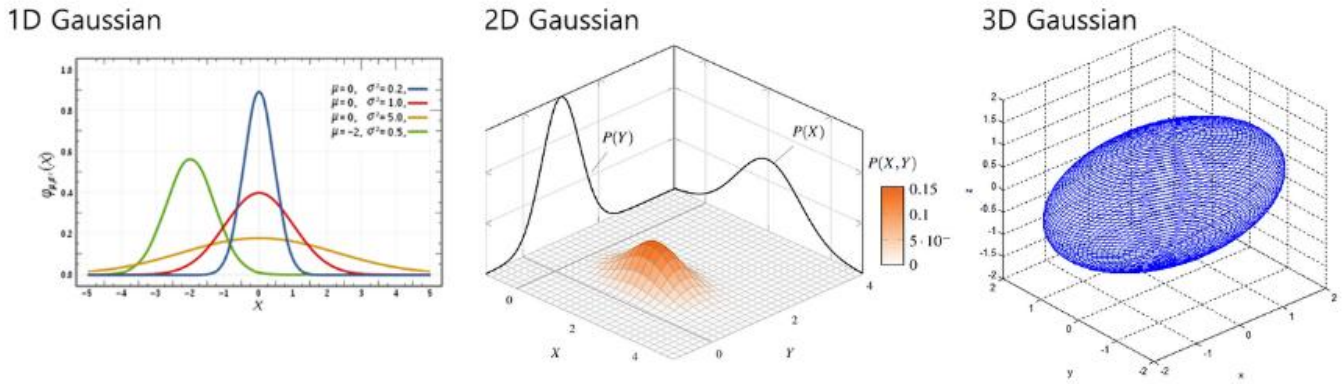

Differentiable 3D Gaussian Splatting

- Scale과 Rotation 분리
  - 타원체의 모양을 결정하는 핵심 요소 분리

$$\Sigma = RSS^T R^T$$

  - 행렬을 통째로 학습시키는 대신, 3D 벡터인 크기(s)와 쿼터니언인 회전(p)값만 독립적으로 학습하게 만듦
  - 3D 가우시안이 구형에 머물지 않고 Anisotropic 형태로 최적화되어, 적은 개수로도 복잡한 이미지를 정밀하게 재구성할 수 있게 됨

Optimization

- 단순히 형태만 학습하는 것이 아니라 각 3D 가우시안의 위치, 불투명도, 공분산, SH 계수를 동시에 최적화

Optimization

- Activation Functions : 딥러닝 최적화 과정(경사하강법)에서 수학적 오류를 막기 위해 특정 함수를 덧씌움
  - 불투명도 : 0 ~ 1 사이의 유효한 범위를 보장하고 부드러운 gradients를 얻기 위해 Sigmoid 활성화 함수 사용
  - Scale : 크기가 음수가 되는 물리적 오류를 막기 위해 Exponential 활성화 함수를 적용

Optimization

- Initialization
  - SfM 포인트에서 최초 생성 시, 가장 가까운 3개 점까지의 거리 평균을 축으로 삼음.
  - 안정적인 Isotropic 가우시안으로 초기 공분산 추정.
- Scheduling
  - 정밀한 디테일 복원을 위해, 위치(Position) 파라미터에 대해서만 Exponential decay 스케줄링 적용.

Optimization

- Loss Function : 렌더링된 이미지와 실제 사진의 오차를 계산하기 위해 픽셀 단위의 색상차이(L1)와 구조적 차이(D-SSIM)를 결합함.

$$L = (1 - \lambda)L1 + \lambda LD - SSIM$$

Adaptive Control of Gaussians

- 실행 주기 (Densification) : 웜업 단계 이후, 매 100회 학습마다 밀집화 수행.
- 기본 청소 (Pruning) : 불투명도가 임계값 이하인 투명한 가우시안은 주기적으로 삭제.

Adaptive Control of Gaussians

- 밀집화 대상: 빈 공간 (Under-reconstruction) 또는 크게 뭉뚱그려진 곳 (Over-reconstruction).
- 판단 기준: 위치 수정을 위해 강한 피드백(큰 위치 기울기)을 받는 가우시안을 감지하여 타겟팅.

Adaptive Control of Gaussians

- Clone
  - 대상: 디테일이 부족한 '작은' 가우시안
  - 방법: 동일한 크기로 복사 후 기울기 방향으로 이동시킴 (전체 부피 증가)
- Split
  - 대상: 분산이 큰 '거대한' 가우시안
  - 방법: 1개를 2개로 쪼개고 크기를 축소함 (전체 부피 유지)

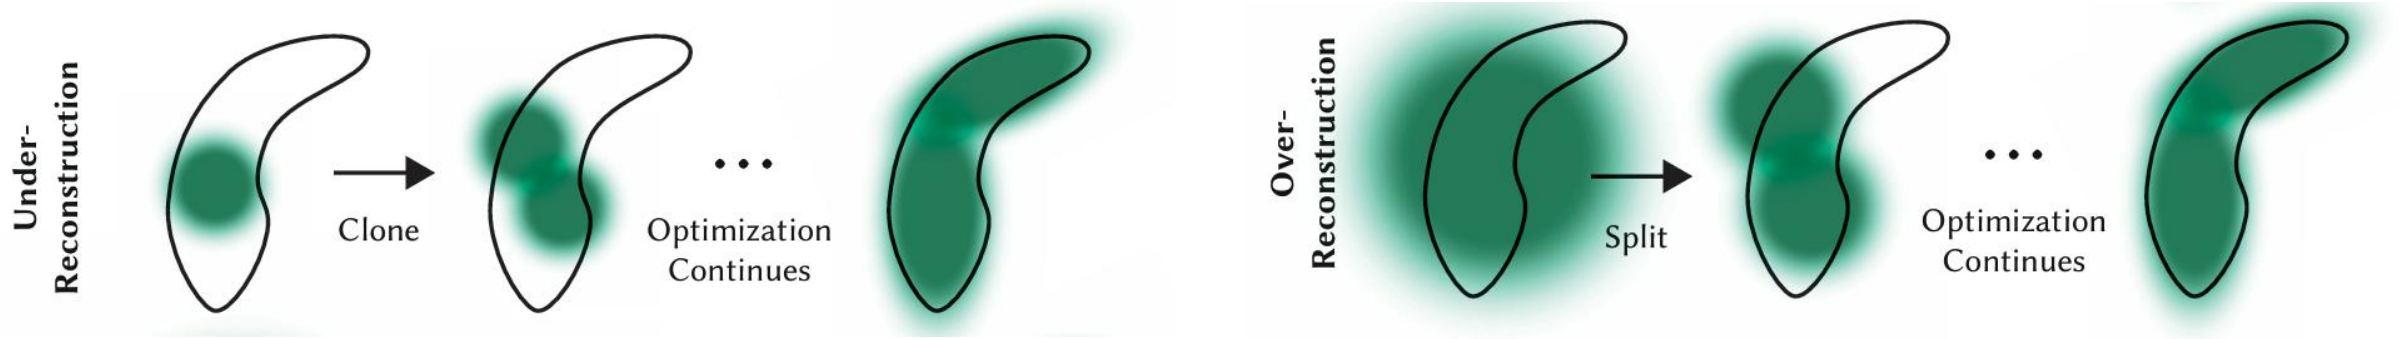

Adaptive Control of Gaussians

- 문제점: 카메라 렌즈 바로 앞 허공에 가우시안이 뭉쳐 팽창하는 부유물(Floaters) 발생.
- 해결책 (투명도 리셋): 매 3000회 학습마다 모든 가우시안의 불투명도를 0에 가깝게 강제 초기화.
- 결과: 필요한 가우시안은 다시 불투명도가 복구되며, 쓸모없는 부유물은 투명하게 남아있다가 기본 청소 룰에 의해 삭제됨

Adaptive Control of Gaussians

- 크기 기반 강제 삭제: 월드 공간이나 뷰 공간에서 비정상적으로 커진 가우시안들을 주기적으로 강제 삭제하여 전체 개수 제어.
- 유클리드 공간 유지: 먼 공간을 압축하거나 왜곡시키는 기존 NeRF 방식과 달리, 철저히 있는 그대로의 3D 유클리드 공간 (Euclidean space) 데이터로 유지하여 연산량 최적화.

Fast Differentiable Rasterizer For Gaussians

- 렌더러 설계 목표
  - 비등방성 가우시안들을 순서대로 초고속 정렬하여 렌더링. 이전 기술의 '학습 점 개수 제한' 한계 극복.
- Tile-split & Culling
  - 화면을 16x16 타일 격자로 분할하여 병목 제거. 카메라 시야각 밖이거나 수학적 오류를 유발할 수 있는 극단적인 점들은 Guard band로 미리 걸러냄(Culling).
- 초고속 정렬 (Fast Radix Sort)
  - 가우시안이 속한 타일과 깊이를 결합한 고유 식별 key 부여. 무거운 픽셀 단위 정렬 대신, 단일 고속 GPU 기수 정렬을 한 번만 실행해 초고속으로 순서 정렬.

Forward & Backward Pass

- Forward Pass & Early-stop
  - 정렬된 명부를 앞쪽부터(front-to-back) 읽으며 α 누적. 투명도가 100%에 도달해 시야가 막히면 해당 스레드를 즉시 중지하여 보이지 않는 뒷면 계산 낭비를 차단.
- 무제한 역전파 (Unlimited Backward Pass)
  - 투명도가 꽉 찰 때까지 겹쳐진 '모든' 가우시안에게 제한 없이 오차(Gradient)를 피드백하여 학습 정확도 극대화.
- Zero-overhead Gradient
  - 중간 투명도 기록을 전부 저장하면 시스템이 다운됨. 순방향 연산이 끝났을 때의 최종 누적 불투명도 1개만 저장. 역전파 시 이 값을 나누어 중간값을 역산출함으로써 초고속 무제한 학습 가능

Implementation & Optimization

- 하드웨어 최적화 : PyTorch 기반 + 커스텀 CUDA 및 고속 정렬 (CUB)로 속도 확보.
- 해상도 Warm-up : 4배 낮은 해상도에서 시작해 점진적으로 해상도를 높여 안정성 확보.
- 순차적 SH 학습 : 빛 반사 오류 방지를 위해 처음 1000번은 기본 색상만, 이후 반사광 도입.

Results vs Mip-NeRF360

- SOTA 화질 달성: 기존 최고 모델(Mip-NeRF360)과 동등하거나 그 이상의 화질 보장.
- 초고속 학습: 48시간 소요되던 학습을 35~45분으로 단축 (약 70배 향상).
- 실시간 렌더링 달성: 1080p 고해상도 환경에서 130 FPS 이상 (세계 최초).

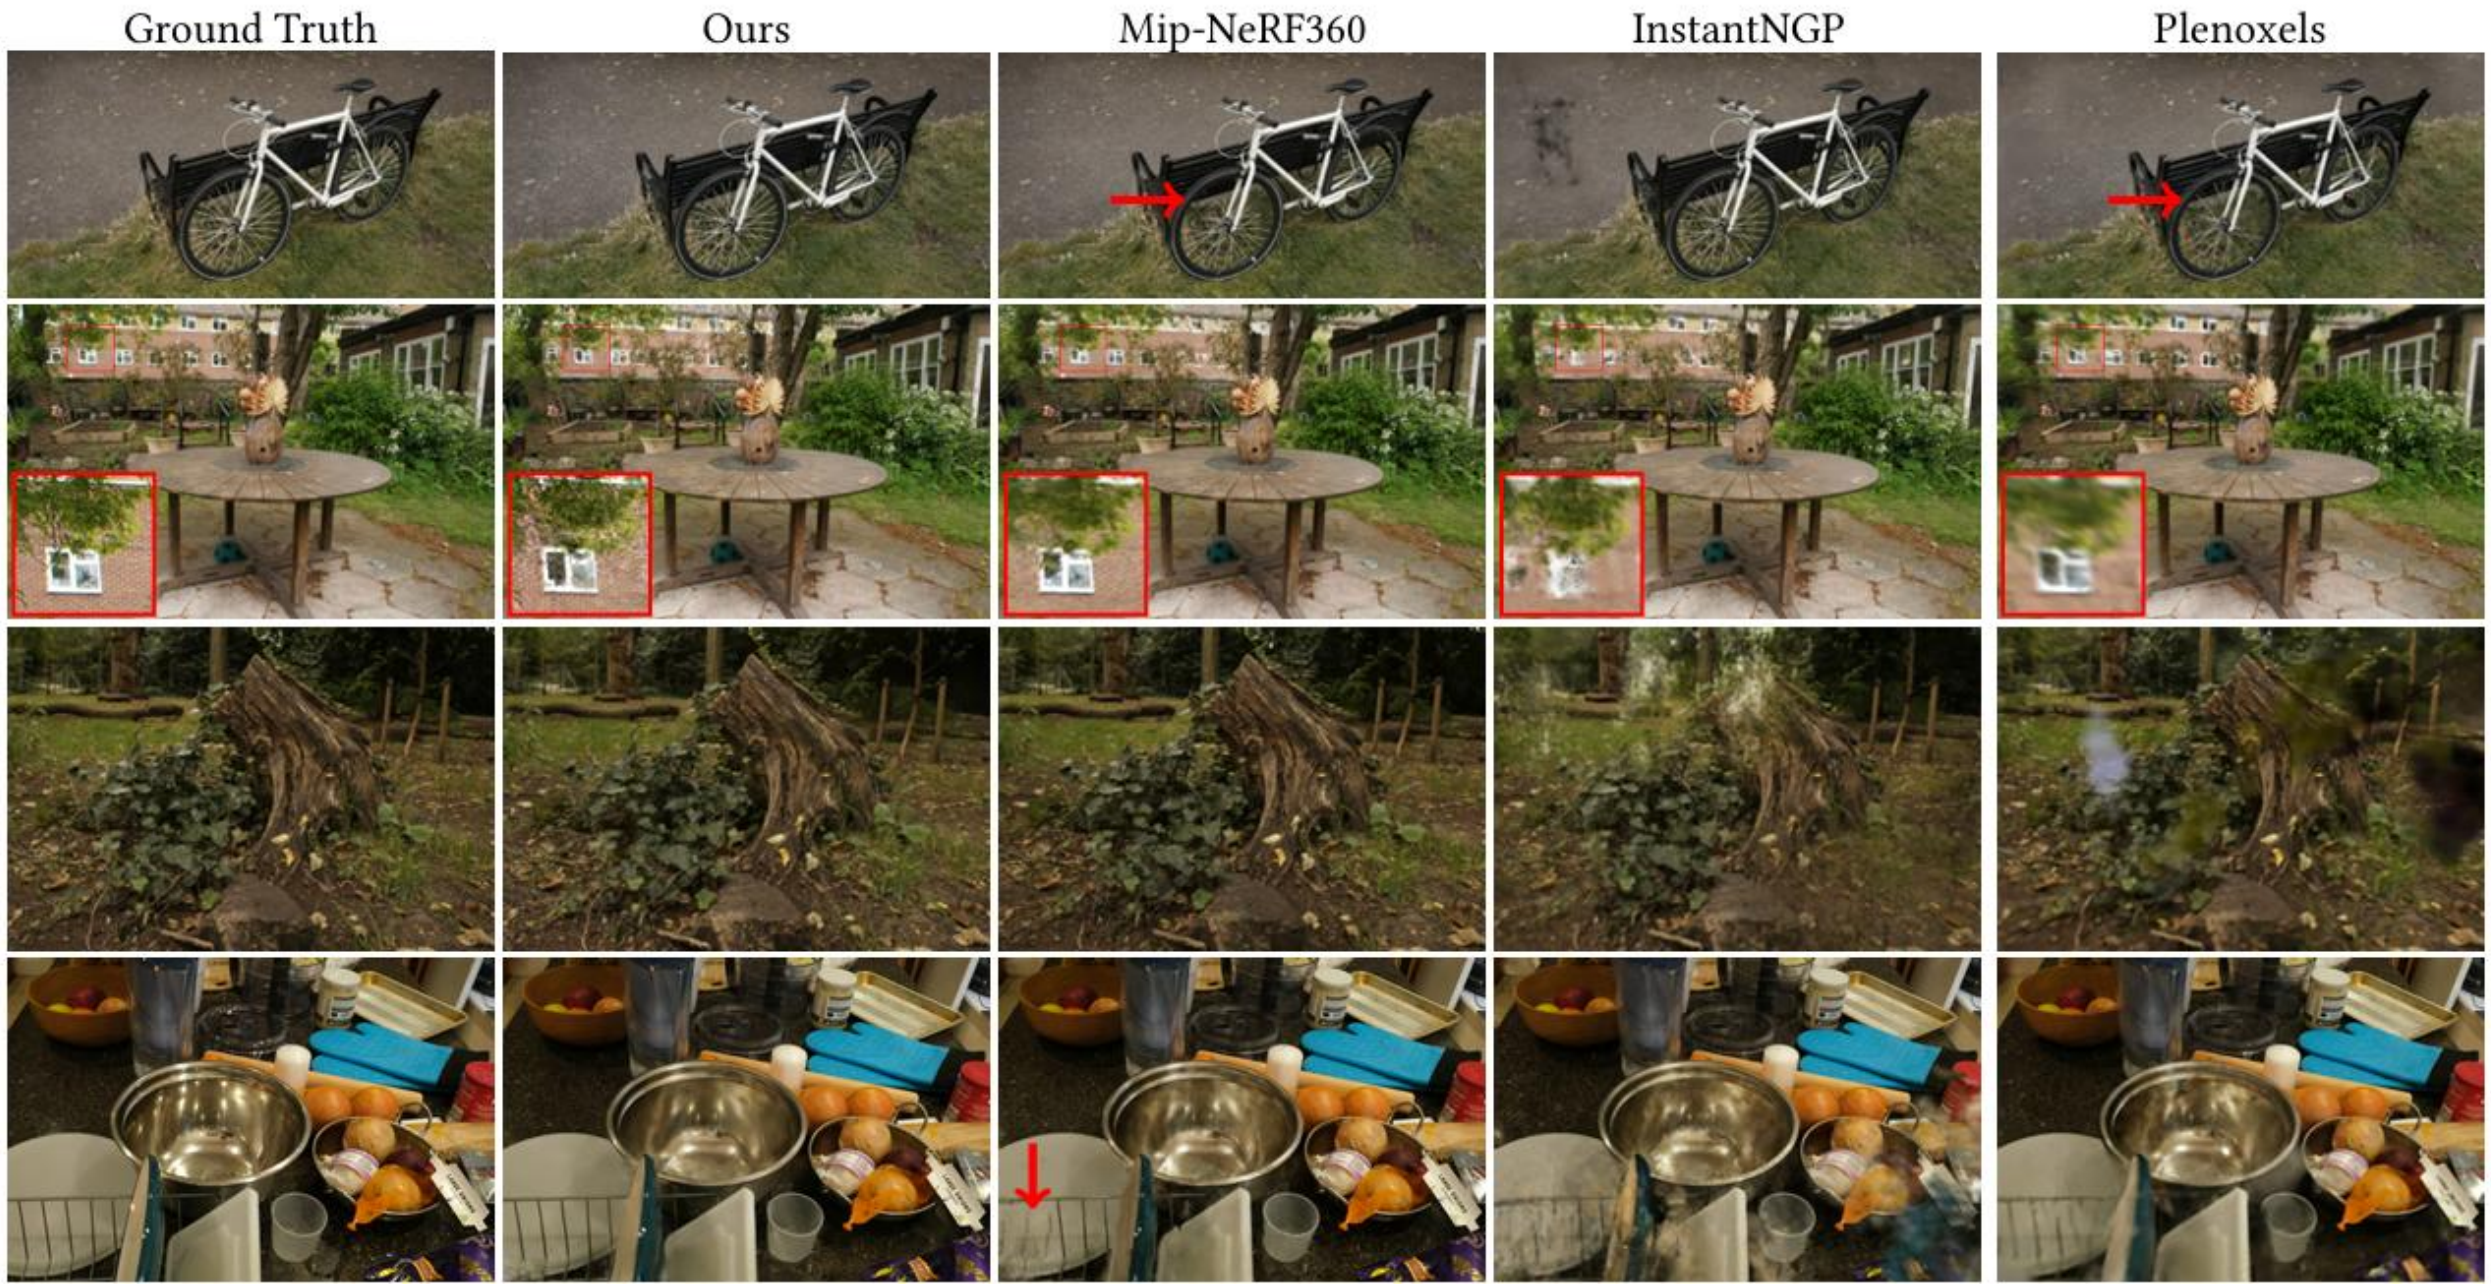
Ground Truth
Ours
Mip-NeRF360
InstantNGP
Plenoxels

SfM Init

- 랜덤 초기화 대비, SfM 점 사용 시 뒷배경 화질이 획기적으로 향상됨.

Densification

- Split : 거대한 점을 나누어 뭉개진 배경을 선명하게 개선.
- Clone : 바퀴 등 얇고 복잡한 구조물을 완벽히 복원.

Unlimited Gradients

- 메모리 최적화를 핑계로 학습 점을 제한하면 화질이 심각하게 붕괴됨 (PSNR 11dB 하락).

Anisotropic

- Isotropic 고정 시 점이 낭비되고 화질이 저하됨. 자유롭게 찌그러지는 형태 변형이 고화질 달성의 필수 요소.

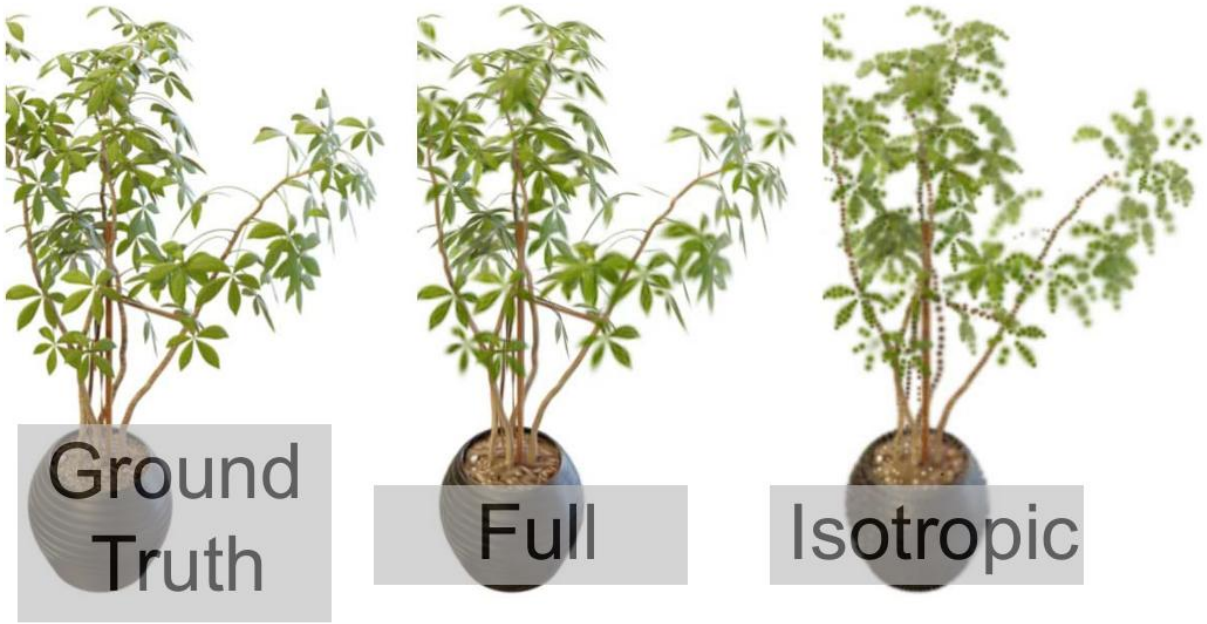

Limitations

- 카메라에 잘 찍히지 않은 사각지대의 경우, 가우시안이 비정상적으로 길쭉해지거나 벽에 얼룩 같은 아티팩트가 생길 수 있음.
- 특정 각도에서 거대한 가우시안이 갑자기 튀어나오는 팝핑(Popping) 현상이나 겹침 순서가 깜빡이는 오류가 간혹 발생.
- 향후 수학적 정규화(Regularization)와 안티앨리어싱을 도입하면 이러한 문제들을 크게 개선할 수 있을 것.

Conclusion

- 연속적인 볼륨 표현(NeRF)이 필수라는 기존 학계의 고정관념을 탈피함.
- Discrete한 3D 가우시안만으로도 최고 수준의 화질과 초고속 렌더링 가능하게 함.